

LAPORAN EVALUASI AKHIR SEMESTER (EAS)
MATA KULIAH DEEP LEARNING - B
“DETEKSI PENYAKIT TANAMAN BERDASARKAN CITRA
DAUN MENGGUNAKAN METODE CONVOLUTIONAL
NEURAL NETWORK (CNN)”



Oleh:

1. Diajeng Sekar Prameswari (22083010003)
2. Armalia Kusuma Putri (22083010004)
3. Annabel Gracia Puryani (22083010048)
4. Cindi Adam (22083010094)
5. Setyobudi Utomo (22083010112)

DOSEN PENGAMPU:

PROGRAM STUDI SAINS DATA
FAKULTAS ILMU KOMPUTER
UNIVERSITAS PEMBANGUNAN NASIONAL “VETERAN”
JAWA TIMUR
2025

DAFTAR ISI

DAFTAR ISI.....	1
BAB 1 PENDAHULUAN.....	2
1.1 Latar Belakang.....	2
1.2 Rumusan Masalah.....	3
1.3 Tujuan.....	4
BAB 2 TINJAUAN PUSTAKA.....	5
2.1. Kecerdasan Buatan (Artificial Intelligence).....	5
2.2. Convolutional Neural Network (CNN).....	5
2.3. Arsitektur Convolutional Neural Network.....	6
2.4. Dataset PlatVillage.....	7
2.5. Penyakit Tanaman pada Daun.....	7
2.6. Klasifikasi Citra.....	8
BAB 3 METODOLOGI PENELITIAN.....	10
3.1 Deskripsi Data.....	10
3.2 Langkah Analisis.....	10
BAB 4 HASIL DAN PEMBAHASAN.....	17
4.1 Exploratory Data Analysis (EDA).....	17
4.2 Data Preprocessing.....	19
4.3 Pembangunan Arsitektur CNN.....	21
4.4 Training Model CNN.....	22
4.5 Evaluasi Model.....	22
4.6 Visualisasi Hasil Prediksi Model.....	24
4.7 Analisis Distribusi Hasil Prediksi Model.....	25
BAB 5 HASIL DAN PEMBAHASAN.....	27
4.1 Kesimpulan.....	27
DAFTAR PUSTAKA.....	28

BAB 1

PENDAHULUAN

1.1 Latar Belakang

Sektor pertanian merupakan salah satu sektor penting dalam menunjang ketahanan pangan dan perekonomian. Namun demikian, sektor ini masih menghadapi berbagai permasalahan, salah satunya adalah serangan penyakit tanaman. Penyakit tanaman dapat menyebabkan penurunan kualitas dan kuantitas hasil panen secara signifikan. Apabila tidak terdeteksi sejak dini, penyakit dapat menyebar dengan cepat dan menimbulkan kerugian bagi petani. Oleh karena itu, upaya deteksi penyakit tanaman menjadi hal yang sangat penting untuk dilakukan. Pemanfaatan teknologi diharapkan dapat menjadi solusi dalam mengatasi permasalahan tersebut (Chapaneri et al., 2020).

Deteksi penyakit tanaman secara konvensional umumnya dilakukan melalui pengamatan visual terhadap kondisi daun tanaman. Metode ini sangat bergantung pada pengalaman dan keahlian petani atau tenaga ahli. Selain itu, proses identifikasi manual membutuhkan waktu yang relatif lama dan berpotensi menimbulkan kesalahan subjektif. Tidak semua petani memiliki akses langsung terhadap pakar tanaman. Kondisi ini dapat menyebabkan keterlambatan dalam penanganan penyakit tanaman. Oleh karena itu, diperlukan sistem otomatis yang mampu membantu proses identifikasi penyakit tanaman secara lebih efisien (Kumar et al., 2020).

Perkembangan teknologi kecerdasan buatan, khususnya dalam bidang pengolahan citra digital, memberikan peluang besar dalam mendeteksi penyakit tanaman. Salah satu metode yang banyak digunakan adalah Convolutional Neural Network (CNN). CNN merupakan metode deep learning yang dirancang khusus untuk mengenali pola visual pada citra (Lu et al., 2021). Metode ini mampu mengekstraksi fitur penting seperti warna, tekstur, dan bentuk daun secara otomatis. Dengan kemampuan tersebut, CNN sangat sesuai diterapkan pada permasalahan klasifikasi citra daun tanaman. Penerapan CNN diharapkan dapat meningkatkan ketepatan dalam mendeteksi penyakit tanaman (Nikesh et al., 2024).

Penelitian ini menggunakan dataset PlantVillage yang diperoleh dari platform Kaggle. Dataset tersebut terdiri dari sekitar 20.600 citra daun tanaman. Jenis tanaman yang terdapat dalam dataset meliputi paprika, kentang, dan tomat. Dataset ini terbagi ke dalam 15 kelas yang mencakup kondisi daun sehat dan berbagai jenis penyakit tanaman. Setiap kelas memiliki karakteristik visual yang berbeda pada daun. Keberagaman dan jumlah data yang cukup besar menjadikan dataset ini sesuai untuk pelatihan model CNN (Tejaswi, 2019).

Langkah analisis pada penelitian ini dilakukan secara sistematis untuk membangun model klasifikasi penyakit tanaman berbasis CNN. Tahapan dimulai dari pengumpulan data dan eksplorasi data untuk memahami karakteristik serta distribusi kelas. Selanjutnya dilakukan preprocessing data yang meliputi resize citra, normalisasi nilai piksel, dan penerapan data augmentation. Dataset kemudian dibagi menjadi data latih, data validasi, dan data uji. Label kelas diubah menggunakan teknik one-hot encoding agar sesuai dengan kebutuhan model. Setelah itu, arsitektur CNN dibangun dan dilatih menggunakan data latih yang telah dipersiapkan.

Berdasarkan latar belakang tersebut, penelitian ini dilakukan untuk membangun sistem klasifikasi daun tanaman menggunakan metode Convolutional Neural Network (CNN). Model yang dibangun selanjutnya dievaluasi untuk mengetahui performanya dalam mengklasifikasikan penyakit tanaman. Evaluasi dilakukan menggunakan data yang tidak terlibat dalam proses pelatihan. Metrik yang digunakan dalam penelitian ini meliputi accuracy dan loss. Selain itu, dilakukan visualisasi hasil pelatihan untuk melihat perkembangan kinerja model. Diharapkan hasil penelitian ini dapat menjadi solusi pendukung dalam deteksi penyakit tanaman secara otomatis dan akurat.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan pada bagian sebelumnya, maka diperlukan perumusan masalah agar penelitian ini memiliki fokus dan batasan yang jelas. Rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana penerapan metode Convolutional Neural Network (CNN) dalam melakukan klasifikasi daun tanaman untuk deteksi penyakit tanaman?
2. Seberapa baik performa model CNN dalam membedakan daun tanaman yang sehat dan daun tanaman yang terkena penyakit menggunakan dataset PlantVillage?
3. Bagaimana hasil klasifikasi penyakit tanaman berdasarkan citra daun yang dihasilkan oleh model CNN?

1.3 Tujuan

Berdasarkan latar belakang dan permasalahan yang telah diuraikan sebelumnya, penelitian ini bertujuan untuk menerapkan teknologi kecerdasan buatan dalam mendeteksi penyakit tanaman secara otomatis melalui citra daun. Adapun tujuan yang ingin dicapai dalam penelitian ini adalah sebagai berikut:

1. Menerapkan metode Convolutional Neural Network (CNN) untuk melakukan klasifikasi daun tanaman berdasarkan kondisi sehat dan sakit.
2. Menggunakan dataset PlantVillage sebagai data latih dan data uji dalam proses pembangunan model klasifikasi penyakit tanaman.
3. Menghasilkan model klasifikasi penyakit tanaman berbasis CNN yang mampu mendeteksi kondisi daun tanaman secara otomatis berdasarkan citra daun.

BAB 2

TINJAUAN PUSTAKA

2.1. Kecerdasan Buatan (*Artificial Intelligence*)

Kecerdasan buatan (*Artificial Intelligence*) merupakan cabang ilmu komputer yang bertujuan untuk mengembangkan sistem yang mampu meniru kemampuan manusia dalam berpikir dan mengambil keputusan. Sistem kecerdasan buatan dirancang agar dapat mempelajari pola dari data dan memberikan respons secara otomatis. Perkembangan kecerdasan buatan sangat pesat seiring dengan meningkatnya ketersediaan data dan kemampuan komputasi. Teknologi ini telah banyak diterapkan pada berbagai bidang, seperti kesehatan, industri, dan pendidikan. Dalam bidang pertanian, kecerdasan buatan mulai dimanfaatkan untuk membantu menyelesaikan berbagai permasalahan. Salah satu penerapannya adalah dalam deteksi penyakit tanaman (Garg et al., 2024).

Pemanfaatan kecerdasan buatan di bidang pertanian bertujuan untuk meningkatkan efisiensi dan produktivitas. Sistem berbasis kecerdasan buatan dapat membantu petani dalam memantau kondisi tanaman secara lebih akurat. Selain itu, teknologi ini mampu memberikan analisis dan rekomendasi berdasarkan data yang tersedia. Pendekatan ini dinilai lebih efektif dibandingkan metode konvensional yang bergantung pada pengamatan manual. Salah satu pendekatan yang banyak digunakan dalam kecerdasan buatan adalah pembelajaran mesin dan deep learning. Deep learning sangat efektif untuk memproses data tidak terstruktur, seperti citra (Pal et al., 2023).

2.2. *Convolutional Neural Network* (CNN)

Convolutional Neural Network (CNN) merupakan salah satu metode deep learning yang dirancang khusus untuk mengolah data berbentuk citra. CNN bekerja dengan mengekstraksi fitur visual dari gambar secara otomatis melalui beberapa lapisan jaringan saraf. Metode ini terinspirasi dari cara kerja sistem visual manusia dalam mengenali objek. CNN mampu mengenali pola seperti tepi, tekstur, dan bentuk objek pada citra. Kemampuan tersebut menjadikan CNN

banyak digunakan dalam pengolahan citra digital. Contoh penerapan CNN meliputi klasifikasi gambar dan deteksi objek (Gupta et al., 2024).

CNN memiliki keunggulan dalam menangani data citra dengan kompleksitas tinggi. Model CNN dapat mempelajari fitur secara bertahap dari yang sederhana hingga kompleks. Proses ini memungkinkan CNN mengenali perbedaan visual antar kelas secara lebih akurat. Dalam konteks penelitian ini, CNN digunakan untuk membedakan daun tanaman yang sehat dan daun yang terkena penyakit. Penggunaan CNN diharapkan dapat meningkatkan akurasi klasifikasi dibandingkan metode konvensional. Oleh karena itu, CNN dipilih sebagai metode utama dalam penelitian ini (Voditel et al., 2023).

2.3. Arsitektur *Convolutional Neural Network*

Arsitektur CNN terdiri dari beberapa layer yang tersusun secara berurutan dan saling terhubung. Setiap layer memiliki peran penting dalam proses pembelajaran fitur dan klasifikasi citra. Layer-layer tersebut dirancang untuk mengekstraksi informasi visual dari citra input. Proses ini dilakukan secara bertahap untuk memperoleh fitur yang relevan. Arsitektur CNN memungkinkan model mempelajari pola visual secara mendalam. Hal ini membuat CNN sangat efektif dalam pengolahan citra (Saleem et al., 2022).

Convolutional layer merupakan layer utama yang berfungsi untuk mengekstraksi fitur dari citra menggunakan filter atau kernel. Filter tersebut akan menghasilkan feature map yang merepresentasikan pola tertentu. Setelah itu, fungsi aktivasi ReLU diterapkan untuk menambahkan sifat non-linear pada jaringan. ReLU membantu meningkatkan kemampuan model dalam mempelajari pola yang kompleks. Selanjutnya, pooling layer digunakan untuk mengurangi dimensi data dan mempertahankan informasi penting. Proses ini membantu mengurangi kompleksitas model (Chen, 2023).

Flatten layer berfungsi untuk mengubah data dua dimensi menjadi satu dimensi. Transformasi ini diperlukan agar data dapat diproses oleh fully connected layer. Fully connected layer berperan dalam proses pengambilan keputusan berdasarkan fitur yang telah diekstraksi. Pada bagian akhir arsitektur, digunakan softmax layer sebagai output. Softmax menghasilkan nilai probabilitas

untuk setiap kelas. Kelas dengan probabilitas tertinggi dipilih sebagai hasil prediksi (Chen, 2023).

2.4. Dataset PlatVillage

Dataset PlantVillage merupakan dataset citra daun tanaman yang banyak digunakan dalam penelitian deteksi penyakit tanaman. Dataset ini tersedia secara publik dan dapat diakses melalui platform Kaggle. PlantVillage menyediakan citra daun dengan berbagai kondisi, mulai dari sehat hingga terkena penyakit. Dataset ini sering digunakan karena kualitas citranya cukup baik. Selain itu, dataset ini memiliki jumlah data yang besar. Hal tersebut mendukung proses pelatihan model deep learning (Tejaswi, 2019).

Pada penelitian ini, dataset PlantVillage terdiri dari sekitar 20.600 citra daun tanaman. Dataset mencakup beberapa jenis tanaman, seperti paprika, kentang, dan tomat. Setiap jenis tanaman memiliki beberapa kelas penyakit yang berbeda. Total terdapat 15 kelas yang merepresentasikan kondisi sehat dan berbagai penyakit tanaman. Keberagaman kelas memungkinkan model mempelajari berbagai pola visual penyakit. Dataset ini sangat sesuai digunakan untuk membangun model klasifikasi (Tejaswi, 2019).

2.5. Penyakit Tanaman pada Daun

Penyakit tanaman merupakan gangguan pada tanaman yang disebabkan oleh organisme patogen, seperti bakteri, jamur, virus, dan hama. Penyakit ini dapat menghambat pertumbuhan tanaman serta menurunkan kualitas dan kuantitas hasil panen. Gejala penyakit tanaman umumnya terlihat jelas pada bagian daun. Daun yang terserang penyakit akan mengalami perubahan visual, seperti perubahan warna, munculnya bercak, dan kerusakan jaringan. Gejala tersebut dapat diamati secara visual melalui citra daun. Oleh karena itu, daun menjadi bagian tanaman yang sangat penting dalam proses deteksi penyakit (Vishnoi et al., 2021).

Dalam dataset PlantVillage, terdapat beberapa jenis penyakit tanaman yang menyerang tanaman paprika, kentang, dan tomat. Pada tanaman paprika (pepper), dataset mencakup kondisi daun sehat dan daun yang terserang penyakit

bacterial spot. Penyakit bacterial spot ditandai dengan munculnya bercak gelap pada permukaan daun yang dapat menyebar secara cepat. Pada tanaman kentang (potato), dataset mencakup kondisi sehat serta penyakit early blight dan late blight. Penyakit early blight biasanya ditandai dengan bercak cokelat berbentuk lingkaran, sedangkan late blight menyebabkan bercak gelap yang lebih luas dan tidak beraturan. Perbedaan visual ini menjadi ciri khas masing-masing penyakit (Ilhamsyah & Enri, 2022).

Tanaman tomat memiliki jumlah kelas penyakit yang lebih beragam dalam dataset PlantVillage. Penyakit yang terdapat pada tanaman tomat meliputi bacterial spot, early blight, late blight, leaf mold, septoria leaf spot, spider mites, target spot, tomato yellow leaf curl virus, dan tomato mosaic virus. Setiap penyakit memiliki pola visual yang berbeda pada daun, seperti perubahan warna, munculnya bercak kecil atau besar, hingga daun yang menggulung atau mengering. Selain itu, dataset juga menyediakan kelas daun tomat sehat sebagai pembandingan. Keberagaman jenis penyakit ini memberikan tantangan sekaligus peluang bagi model klasifikasi. Model CNN dapat mempelajari perbedaan visual antar penyakit secara lebih mendalam (Hamami & Dahlan, 2022).

Perbedaan karakteristik visual antar penyakit tanaman dapat dimanfaatkan sebagai dasar dalam proses klasifikasi citra. Melalui citra daun, sistem dapat mengenali pola-pola tertentu yang menunjukkan jenis penyakit tanaman. Pendekatan berbasis citra memungkinkan proses deteksi dilakukan secara otomatis tanpa harus bergantung pada pengamatan manual. Dengan memanfaatkan metode CNN, proses identifikasi penyakit tanaman dapat dilakukan dengan lebih cepat dan akurat. Deteksi dini penyakit tanaman sangat penting untuk mencegah penyebaran penyakit yang lebih luas. Oleh karena itu, penggunaan citra daun menjadi solusi yang efektif dalam mendukung sistem deteksi penyakit tanaman (Kumar, 2023).

2.6. Klasifikasi Citra

Klasifikasi citra merupakan proses pengelompokan citra ke dalam kelas tertentu berdasarkan karakteristik visual yang dimilikinya. Karakteristik visual tersebut dapat berupa warna, tekstur, bentuk, dan pola yang muncul pada citra.

Tujuan utama dari klasifikasi citra adalah untuk mengidentifikasi objek atau kondisi tertentu yang terdapat pada sebuah gambar. Dalam pengolahan citra digital, klasifikasi menjadi tahap penting karena menentukan hasil akhir dari analisis citra. Klasifikasi citra telah banyak diterapkan dalam berbagai bidang, termasuk bidang pertanian. Pada penelitian ini, klasifikasi citra digunakan untuk membedakan kondisi daun tanaman yang sehat dan yang terkena penyakit (Khedkar, 2024).

Pada pendekatan deep learning, proses ekstraksi fitur dan proses klasifikasi dilakukan secara otomatis oleh model. Convolutional Neural Network (CNN) mempelajari fitur-fitur penting langsung dari citra selama proses pelatihan. Fitur yang dipelajari mencakup pola visual yang membedakan satu kelas dengan kelas lainnya. Pendekatan ini dinilai lebih efektif dibandingkan metode konvensional yang menggunakan ekstraksi fitur secara manual. CNN juga mampu menangani data citra yang kompleks dan memiliki variasi tinggi. Dalam penelitian ini, CNN digunakan sebagai model klasifikasi utama untuk mengevaluasi kinerja sistem deteksi penyakit tanaman (Kusumo et al., 2020).

BAB 3

METODOLOGI PENELITIAN

3.1 Deskripsi Data

Data yang digunakan dalam project ini adalah *PlantVillage Dataset*, yaitu dataset citra daun tanaman yang banyak digunakan untuk penelitian deteksi penyakit berbasis deep learning. Dataset ini terdiri dari gambar daun yang berasal dari tiga jenis tanaman utama, yaitu *pepper* (paprika), *potato* (kentang), dan *tomato* (tomat). Setiap gambar telah dikategorikan ke dalam folder berdasarkan jenis tanaman sekaligus jenis penyakit atau kondisi sehatnya, sehingga struktur dataset sudah siap digunakan untuk melatih model klasifikasi berbasis CNN.


Secara keseluruhan dataset ini mencakup 15 kelas, yang merepresentasikan berbagai penyakit daun seperti *bacterial spot*, *early blight*, *late blight*, *leaf mold*, *septoria leaf spot*, *spider mites*, *target spot*, serta dua jenis virus pada tanaman tomat. Selain itu, dataset juga menyediakan kelas daun sehat dari masing-masing tanaman. Total keseluruhan gambar dalam dataset yang digunakan pada project ini adalah sekitar 20.000 gambar berwarna (RGB) dengan format JPG.

Ukuran gambar bervariasi, namun kualitas citra secara keseluruhan cukup konsisten dan jelas sehingga cocok digunakan untuk proses pelatihan model CNN. Struktur folder yang terorganisir per kelas mempermudah proses loading data, preprocessing, dan pemetaan label selama pengembangan model.

3.2 Langkah Analisis

Penelitian ini dilakukan melalui beberapa tahapan analisis yang saling berurutan. Proses dimulai dari pengumpulan dataset citra daun tanaman, kemudian dilakukan analisis awal untuk melihat kondisi dan distribusi data. Setelah itu, data diproses agar siap digunakan sebagai input model CNN. Tahap berikutnya adalah pembuatan dan pelatihan model CNN untuk melakukan klasifikasi citra daun tanaman. Selanjutnya, model dievaluasi untuk mengetahui

tingkat keakuratan hasil klasifikasi. Tahap terakhir berupa visualisasi dan analisis hasil prediksi model. Untuk mempermudah pemahaman alur penelitian, seluruh tahapan analisis disajikan dalam bentuk flowchart yang menunjukkan urutan proses dari awal hingga akhir.



Gambar 3.1. Langkah Analisis

Langkah analisis pada project ini dilakukan melalui beberapa tahapan sistematis untuk membangun model klasifikasi penyakit tanaman berbasis *Convolutional Neural Network* (CNN). Adapun langkah-langkah analisis yang dilakukan adalah sebagai berikut:

A. Data Collecting

Pada tahap ini, data diambil dari *PlantVillage Dataset* yang tersedia di Kaggle. Dataset terdiri dari citra daun tanaman paprika, kentang, dan tomat yang sudah terbagi ke dalam 15 kelas penyakit dan kondisi sehat. Seluruh folder kemudian diunduh dan disiapkan untuk proses analisis.

B. Eksplorasi Data (*Exploratory Data Analysis* / EDA)

Tahap eksplorasi data dilakukan untuk memahami karakteristik awal dataset sebelum dilakukan preprocessing dan pemodelan. Pada tahap ini, dilakukan analisis terhadap jumlah kelas dan distribusi citra pada setiap kelas untuk mengetahui keseimbangan data. Selain itu, beberapa contoh citra dari masing-masing kelas divisualisasikan untuk mengamati variasi ukuran resolusi, kondisi pencahayaan, serta pola visual penyakit pada daun tanaman. Hasil eksplorasi menunjukkan bahwa citra memiliki ukuran dan kondisi pencahayaan yang beragam, sehingga diperlukan tahap preprocessing sebelum data digunakan sebagai input model CNN.

C. Data Preprocessing

Tahap preprocessing data bertujuan untuk menyiapkan citra agar sesuai dengan kebutuhan input model *Convolutional Neural Network* (CNN).

Berdasarkan hasil eksplorasi data sebelumnya, dilakukan beberapa langkah preprocessing sebagai berikut:

1) *Resize Gambar*

Pada tahap ini, seluruh citra diubah ukurannya menjadi dimensi yang seragam, yaitu 224×224 piksel. Proses *resize* diperlukan karena model CNN memerlukan ukuran input yang tetap. Selain itu, penyeragaman ukuran citra juga membantu mengurangi kompleksitas komputasi tanpa menghilangkan informasi penting pada gambar.

2) *Normalisasi Piksel*

Normalisasi dilakukan dengan mengubah nilai piksel citra ke dalam rentang 0-1. Langkah ini bertujuan untuk menstabilkan proses pelatihan model karena jaringan saraf bekerja lebih optimal ketika nilai input berada pada skala yang seragam. Normalisasi juga membantu mempercepat proses konvergensi selama training.

3) *Data Augmentation*

Data augmentation diterapkan pada data latih untuk meningkatkan variasi citra secara artifisial tanpa mengubah label kelas. Teknik augmentasi yang digunakan meliputi rotasi, *flipping*, *zooming*, *shifting*, dan penyesuaian pencahayaan. Penerapan augmentasi bertujuan untuk meningkatkan kemampuan generalisasi model dan mengurangi risiko overfitting.

4) *Pembagian Dataset (Data Splitting)*

Dataset dibagi menjadi tiga bagian, yaitu data latih (*training*), data validasi (*validation*), dan data uji (*testing*). Data latih digunakan untuk melatih model, data validasi digunakan untuk mengevaluasi performa model selama proses training, sedangkan data uji digunakan untuk mengukur performa akhir model terhadap data yang belum pernah dilihat sebelumnya.

5) *One-Hot Encoding Label*

Label kelas yang semula berbentuk kategori diubah menjadi representasi vektor biner menggunakan teknik one-hot

encoding. Label akan diubah menjadi format seperti $[1,0,0]$, $[0,1,0]$, atau $[0,0,1]$. Transformasi ini diperlukan agar model CNN dapat mempelajari setiap kelas sebagai output yang berbeda dalam bentuk probabilitas.

D. Pembangunan Arsitektur CNN

Tahap ini berfokus pada penyusunan arsitektur Convolutional Neural Network (CNN) yang digunakan untuk melakukan klasifikasi citra. Arsitektur CNN disusun secara berurutan untuk mengekstraksi fitur dari citra dan menghasilkan prediksi kelas. Setiap komponen dalam arsitektur memiliki peran tertentu dalam proses pembelajaran model.

1) *Convolutional Layer*

Convolutional layer merupakan inti dari CNN. Layer ini bertugas mengekstraksi fitur penting dari gambar melalui proses konvolusi menggunakan filter atau kernel. Fitur yang diekstraksi bisa berupa edges, tekstur, pola bentuk, hingga fitur kompleks pada layer yang lebih dalam. Semakin banyak convolutional layer, semakin kaya fitur yang dapat dipelajari oleh model.

2) *ReLU Activation*

Setelah proses konvolusi, fungsi aktivasi ReLU (*Rectified Linear Unit*) diterapkan untuk menambahkan non-linearitas pada jaringan. ReLU membantu model belajar pola yang lebih kompleks dan mencegah masalah vanishing gradient. Fungsi ini bekerja sederhana dengan mengubah nilai negatif menjadi nol, sedangkan nilai positif dibiarkan apa adanya.

3) *MaxPooling Layer*

MaxPooling layer digunakan untuk mengurangi dimensi fitur (*downsampling*) sambil mempertahankan informasi paling penting. Dengan mengambil nilai maksimum pada setiap area kecil, layer ini membuat model lebih efisien, mengurangi jumlah parameter, serta membantu mencegah overfitting.

4) *Flatten Layer*

Setelah proses ekstraksi fitur dari *convolution* dan *pooling*, fitur 2D yang dihasilkan diubah menjadi bentuk 1D melalui *flatten layer*. Transformasi ini diperlukan agar data dapat diproses oleh *layer fully connected* pada tahap berikutnya.

5) *Dense (Fully Connected) Layer*

Dense layer berfungsi untuk melakukan proses pengambilan keputusan berdasarkan fitur yang telah diekstraksi sebelumnya. Pada layer ini, model mempelajari hubungan antar fitur yang berkontribusi dalam menentukan kelas citra.

6) *Softmax Layer* sebagai Output

Pada bagian akhir arsitektur, digunakan *softmax layer* sebagai output untuk menghasilkan nilai probabilitas dari setiap kelas. Layer ini memastikan bahwa total probabilitas seluruh kelas bernilai 1, sehingga model dapat memilih kelas dengan probabilitas tertinggi sebagai prediksi akhir.

E. Training Model

Tahap training model merupakan proses melatih arsitektur *Convolutional Neural Network* (CNN) menggunakan data latih yang telah melalui tahap preprocessing. Pada tahap ini, model belajar mengenali pola dan fitur pada citra daun tanaman untuk memetakan input citra ke kelas penyakit yang sesuai. Proses pelatihan dilakukan dengan memasukkan data latih (*training set*) secara bertahap dalam bentuk batch. Pada setiap iterasi, model akan menghitung nilai loss sebagai ukuran kesalahan prediksi, kemudian memperbarui bobot jaringan menggunakan algoritma optimisasi untuk meminimalkan nilai loss tersebut.

Dalam penelitian ini, model dikompilasi menggunakan fungsi *loss categorical cross-entropy* karena permasalahan yang dihadapi merupakan klasifikasi multi-kelas. Algoritma optimisasi yang digunakan adalah Adam optimizer karena kemampuannya dalam mempercepat proses konvergensi dan menyesuaikan laju pembelajaran

secara adaptif. Selain itu, metrik *accuracy* digunakan untuk mengukur tingkat ketepatan prediksi model selama proses pelatihan. Proses training dilakukan selama sejumlah epoch tertentu, di mana pada setiap epoch model dilatih menggunakan seluruh data latih dan dievaluasi menggunakan data validasi. Hasil pelatihan berupa nilai *loss* dan *accuracy* pada data latih dan validasi dicatat untuk dianalisis lebih lanjut.

F. Evaluasi Model

Tahap evaluasi model dilakukan untuk menilai kinerja model *Convolutional Neural Network* (CNN) dalam mengklasifikasikan citra penyakit tanaman. Evaluasi dilakukan menggunakan data yang tidak digunakan selama proses pelatihan, yaitu data validasi dan/atau data uji, sehingga performa model dapat mencerminkan kemampuan generalisasi terhadap data baru. Matrik evaluasi utama yang digunakan pada penelitian ini adalah *accuracy*, yang mengukur persentase prediksi yang benar dibandingkan dengan seluruh data yang diuji. Nilai *accuracy* memberikan gambaran umum mengenai tingkat ketepatan model dalam mengklasifikasikan citra ke dalam kelas yang sesuai.

Selain *accuracy*, evaluasi juga dilakukan dengan mengamati nilai *loss* pada data validasi. Perbandingan antara *loss* dan *accuracy* pada data latih dan data validasi digunakan untuk mendeteksi adanya *overfitting* atau *underfitting*. Hasil evaluasi digunakan sebagai dasar untuk menilai apakah arsitektur CNN yang dibangun telah memberikan performa yang memadai atau masih memerlukan penyesuaian lebih lanjut, seperti perubahan jumlah layer, parameter model, atau strategi preprocessing.

G. Visualisasi Hasil

Visualisasi hasil dilakukan untuk memberikan gambaran yang lebih jelas mengenai kinerja model CNN selama proses pelatihan dan evaluasi. Visualisasi ini membantu dalam memahami proses pembelajaran model serta mengevaluasi stabilitas dan performa model secara visual. Grafik training *accuracy* dan validation *accuracy*

ditampilkan untuk menunjukkan perkembangan tingkat ketepatan model pada setiap epoch selama proses pelatihan. Selain itu, grafik training loss dan validation loss digunakan untuk mengamati perubahan nilai kesalahan model. Perbandingan antara grafik training dan validation dapat digunakan untuk mendeteksi terjadinya *overfitting* atau *underfitting* pada model.

Selain itu, ditampilkan beberapa contoh hasil prediksi model terhadap citra uji. Visualisasi ini memperlihatkan perbandingan antara label asli dan label prediksi yang dihasilkan oleh model, sehingga dapat memberikan gambaran secara kualitatif mengenai kemampuan model dalam mengklasifikasikan penyakit tanaman.

BAB 4

HASIL DAN PEMBAHASAN

4.1 *Exploratory Data Analysis* (EDA)


Tahap *Exploratory Data Analysis* (EDA) dilakukan untuk memahami karakteristik awal dataset *PlantVillage* sebelum dilakukan preprocessing dan pemodelan. Analisis ini difokuskan pada distribusi jumlah citra pada setiap kelas penyakit tanaman untuk mengidentifikasi potensi ketidakseimbangan data. Hasil EDA disajikan dalam bentuk tabel distribusi kelas.

Tabel 4.1. Distribusi Jumlah Citra pada Dataset *PlantVillage*

Nama Kelas	Jumlah Citra
Tomato__Tomato_YellowLeaf__Curl_Virus	3.209
Tomato_Bacterial_spot	2127
Tomato_Late_blight	1909
Tomato_Septoria_leaf_spot	1771
Tomato_Spider_mites_Two_spotted_spider_mite	1676
Tomato_healthy	1591
Pepper__bell__healthy	1478
Tomato__Target_Spot	1404
Potato__Early_blight	1000
Potato__Late_blight	1000
Tomato_Early_blight	1000
Pepper__bell__Bacterial_spot	997
Tomato_Leaf_Mold	952
Tomato__Tomato_mosaic_virus	373
Potato__healthy	152

Hasil eksplorasi data menunjukkan bahwa dataset *PlantVillage* terdiri dari beberapa kelas penyakit tanaman dengan jumlah citra yang berbeda-beda pada setiap kelas. Tabel distribusi kelas memperlihatkan bahwa kelas


Tomato__Tomato_YellowLeaf__Curl_Virus memiliki jumlah citra terbanyak, yaitu sebanyak 3.209 citra, sedangkan kelas lainnya memiliki jumlah citra yang lebih sedikit. Untuk memperjelas distribusi jumlah citra pada setiap kelas, hasil pada Tabel 4.1 selanjutnya divisualisasikan dalam bentuk bar chart.



Gambar 4.1. Distribusi Jumlah Citra pada Setiap Kelas Penyakit Tanaman

Pada Gambar 4.1 menunjukkan perbedaan jumlah citra yang cukup signifikan antar kelas penyakit tanaman. Beberapa kelas memiliki jumlah citra yang jauh lebih banyak dibandingkan kelas lainnya, yang mengindikasikan adanya ketidakseimbangan data pada dataset PlantVillage.

Selain analisis distribusi jumlah data, dilakukan visualisasi contoh citra dari setiap kelas penyakit tanaman. Visualisasi ini bertujuan untuk memberikan gambaran karakteristik visual daun pada masing-masing kelas serta memastikan bahwa seluruh citra telah terbaca dengan baik dan sesuai dengan label kelasnya.



Gambar 4.2. Contoh Citra Daun dari Setiap Kelas Penyakit Tanaman

Pada Gambar 4.2 menampilkan satu contoh citra dari setiap kelas pada dataset *PlantVillage*. Terlihat adanya perbedaan pola, warna, dan tekstur daun pada masing-masing kelas penyakit, yang menunjukkan bahwa citra memiliki karakteristik visual yang relevan dan dapat dipelajari oleh model CNN pada tahap pemodelan selanjutnya.

4.2 Data Preprocessing

Tahap data preprocessing dilakukan untuk menyiapkan citra pada dataset *PlantVillage* sebelum digunakan sebagai input model *Convolutional Neural Network* (CNN). Preprocessing meliputi penyeragaman ukuran citra, normalisasi nilai piksel, penerapan data augmentation, serta pembagian dataset menjadi data latih dan data validasi guna mendukung proses pelatihan model secara optimal.

4.2.1 Penentuan Ukuran Input Citra

Pada penelitian ini, seluruh citra diseragamkan ke ukuran 224×224 piksel sebelum digunakan sebagai input model CNN. Ukuran ini dipilih karena merupakan ukuran standar yang umum digunakan pada arsitektur CNN dan transfer learning, sehingga mampu menjaga keseimbangan antara kualitas informasi citra dan efisiensi komputasi.

4.2.2 Penentuan Ukuran Batch

Proses pelatihan model dilakukan menggunakan batch size sebesar 32 citra pada setiap iterasi. Pemilihan ukuran batch ini bertujuan untuk menjaga stabilitas proses pembelajaran model sekaligus mengoptimalkan penggunaan memori selama proses training.

4.2.3 Normalisasi Nilai Piksel

Normalisasi nilai piksel dilakukan dengan mengubah rentang nilai piksel citra dari 0-255 menjadi 0-1. Langkah ini bertujuan untuk mempercepat konvergensi model serta meningkatkan stabilitas proses pelatihan jaringan saraf.

4.2.4 Penerapan Data Augmentation

Untuk meningkatkan variasi data latih dan memperbaiki kemampuan generalisasi model, diterapkan teknik data augmentation secara real-time selama proses training. Teknik augmentasi yang digunakan meliputi rotasi

citra, pergeseran horizontal dan vertikal, zoom, shear, serta flipping horizontal. Selain itu, dataset dibagi menjadi data latih dan data validasi dengan proporsi 80% data latih dan 20% data validasi, guna mendukung proses evaluasi model selama pelatihan.

4.2.5 Pembentukan Data Latih

Setelah proses preprocessing dilakukan, dataset dibentuk menjadi data latih menggunakan mekanisme pembacaan direktori citra. Hasil proses ini menunjukkan bahwa data latih terdiri dari 16.516 citra yang terbagi ke dalam 15 kelas penyakit tanaman. Hal ini menandakan bahwa dataset berhasil dimuat dan siap digunakan sebagai input pada proses pelatihan model CNN. Selain itu, label kelas secara otomatis dikonversi ke dalam bentuk kategorikal (*one-hot encoding*) untuk mendukung proses klasifikasi multiclass.

4.2.6 Pembentukan Data Validasi

Berdasarkan hasil pembentukan data validasi, diperoleh sebanyak 4.122 citra yang terbagi ke dalam 15 kelas penyakit tanaman. Data validasi ini digunakan untuk mengevaluasi performa model CNN selama proses pelatihan, sehingga dapat diketahui kemampuan model dalam melakukan generalisasi terhadap data yang tidak digunakan pada proses pelatihan. Dengan demikian, total dataset terbagi menjadi 16.516 citra sebagai data latih dan 4.122 citra sebagai data validasi, dengan proporsi pembagian sekitar 80% data latih dan 20% data validasi.

4.2.7 Verifikasi Bentuk Data Hasil Preprocessing

Untuk memastikan bahwa data hasil preprocessing telah sesuai dengan kebutuhan model CNN, dilakukan pengambilan satu batch data dari data latih. Hasil verifikasi menunjukkan bahwa data citra memiliki ukuran (32, 224, 224, 3), yang berarti setiap batch terdiri dari 32 citra berwarna (RGB) dengan ukuran 224×224 piksel. Sementara itu, label kelas memiliki ukuran (32, 15), yang menunjukkan bahwa setiap citra direpresentasikan dalam bentuk one-hot encoding untuk 15 kelas penyakit tanaman. Hasil ini menegaskan bahwa format data dan label telah sesuai dan siap digunakan pada tahap pelatihan model CNN.

Berdasarkan hasil preprocessing dan verifikasi data, seluruh citra dan label telah berada dalam format yang sesuai dengan kebutuhan model CNN, sehingga proses pelatihan dan evaluasi model dapat dilakukan pada tahap selanjutnya.

4.3 Pembangunan Arsitektur CNN

Pembangunan arsitektur *Convolutional Neural Network* (CNN) dilakukan untuk membangun model klasifikasi citra penyakit tanaman berdasarkan data hasil preprocessing yang telah dipersiapkan sebelumnya. Arsitektur CNN dirancang untuk mengekstraksi fitur visual secara bertahap dan menghasilkan prediksi kelas penyakit tanaman.

Tabel 4.2. Ringkasan Arsitektur CNN

Layer (type)	Output Shape	Parameter
conv2d_3 (Conv2D)	(None, 222, 222, 32)	896
max_pooling2d_3 (MaxPooling2D)	(None, 111, 111, 32)	0
conv2d_4 (Conv2D)	(None, 109, 109, 64)	18,496
max_pooling2d_4 (MaxPooling2D)	(None, 54, 54, 64)	0
conv2d_5 (Conv2D)	(None, 52, 52, 128)	73,856
max_pooling2d_5 (MaxPooling2D)	(None, 26, 26, 128)	0
flatten_1 (Flatten)	(None, 86528)	0
dense_4 (Dense)	(None, 256)	22,151,424
dropout_2 (Dropout)	(None, 256)	0
dense_5 (Dense)	(None, 15)	3,855

Berdasarkan Tabel 4.2, arsitektur CNN yang digunakan terdiri dari tiga convolutional layer dengan jumlah filter yang meningkat secara bertahap, yaitu 32, 64, dan 128. Peningkatan jumlah filter ini bertujuan untuk memungkinkan model mempelajari fitur citra dari tingkat sederhana hingga fitur yang lebih kompleks. Setiap convolutional layer diikuti oleh max pooling layer untuk mengurangi dimensi feature map serta menekan kompleksitas komputasi. Setelah proses ekstraksi fitur, feature map diratakan menggunakan flatten layer dan diteruskan ke dense layer dengan 256 neuron. Penggunaan dropout layer

dilakukan untuk mengurangi risiko overfitting. Pada bagian output, digunakan dense layer dengan 15 neuron dan fungsi aktivasi softmax untuk menghasilkan probabilitas prediksi pada setiap kelas penyakit tanaman.

4.4 Training Model CNN

Pelatihan model *Convolutional Neural Network* (CNN) dilakukan menggunakan data latih hasil preprocessing dengan tujuan untuk mempelajari pola dan karakteristik citra daun tanaman. Proses pelatihan dilakukan selama 10 epoch dengan memantau nilai akurasi dan loss pada data latih serta data validasi untuk mengevaluasi kinerja model selama proses pembelajaran.

Berdasarkan hasil pelatihan model, diperoleh perkembangan nilai akurasi dan loss pada setiap epoch sebagaimana ditunjukkan pada output pelatihan. Pada epoch pertama, model menghasilkan akurasi data latih sebesar 31,72% dengan nilai loss sebesar 2,1265, sedangkan akurasi validasi mencapai 69,48%. Seiring bertambahnya epoch, akurasi model mengalami peningkatan yang signifikan dan nilai loss cenderung menurun.

Pada epoch ke-10, model mencapai akurasi data latih sebesar 86,52% dengan nilai loss sebesar 0,3944. Sementara itu, akurasi pada data validasi mencapai 84,79% dengan nilai loss sebesar 0,4704. Hal ini menunjukkan bahwa model mampu mempelajari pola citra dengan baik serta memiliki kemampuan generalisasi yang cukup baik terhadap data validasi.


Peningkatan akurasi dan penurunan nilai loss selama proses pelatihan menunjukkan bahwa model CNN berhasil melakukan proses pembelajaran secara efektif. Meskipun terdapat fluktuasi pada nilai akurasi dan loss validasi di beberapa epoch, model tidak menunjukkan indikasi overfitting yang signifikan, karena perbedaan antara akurasi data latih dan validasi masih berada dalam batas yang wajar.

4.5 Evaluasi Model

Tahap evaluasi model dilakukan untuk menilai kinerja model *Convolutional Neural Network* (CNN) dalam mengklasifikasikan citra daun tanaman ke dalam dua kategori, yaitu sehat dan sakit. Evaluasi dilakukan

menggunakan data uji dengan mengukur nilai akurasi biner serta confusion matrix untuk mengetahui kemampuan model dalam melakukan klasifikasi secara lebih detail. Berdasarkan hasil evaluasi, model CNN memperoleh nilai akurasi biner sebesar 96,19%, yang menunjukkan bahwa model mampu mengklasifikasikan citra daun tanaman ke dalam kelas sehat dan sakit dengan tingkat ketepatan yang sangat tinggi. Selain itu, evaluasi juga dilakukan menggunakan confusion matrix sebagaimana ditunjukkan pada Gambar 4.3. Confusion matrix tersebut terdiri dari:

- A. 956 citra sehat yang berhasil diklasifikasikan dengan benar sebagai sehat.
- B. 4.117 citra sakit yang berhasil diklasifikasikan dengan benar sebagai sakit
- C. 12 citra sehat yang salah diklasifikasikan sebagai sakit.
- D. 189 citra sakit yang salah diklasifikasikan sebagai sehat.



Gambar 4.3. Visualisasi Confusion Matrix Klasifikasi Sehat dan Sakit

Hasil confusion matrix menunjukkan bahwa model memiliki kemampuan yang sangat baik dalam mengenali citra daun yang sakit, ditunjukkan oleh jumlah true positive yang tinggi. Jumlah kesalahan klasifikasi (*false positive* dan *false negative*) relatif kecil dibandingkan dengan total data, sehingga model dapat dikatakan memiliki performa yang stabil dan akurat. Gambar 4.3 menampilkan visualisasi confusion matrix dalam bentuk heatmap. Warna yang lebih gelap menunjukkan jumlah prediksi yang lebih tinggi, sehingga memudahkan interpretasi hasil klasifikasi. Visualisasi ini memperjelas bahwa sebagian besar

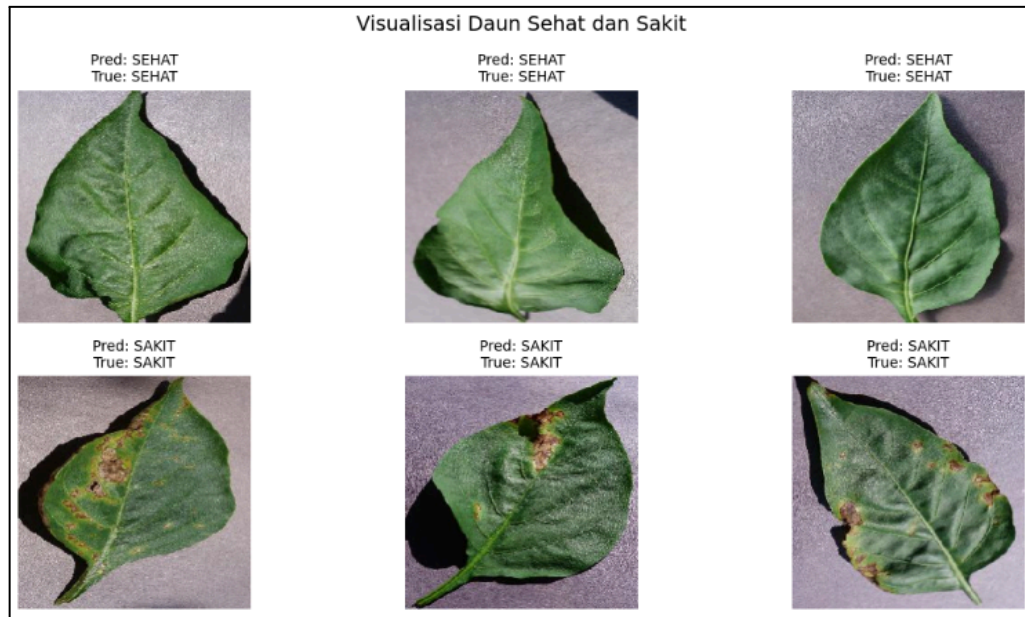
prediksi model berada pada diagonal utama, yang menandakan tingkat prediksi yang akurat.

Tingginya nilai akurasi biner dan dominasi prediksi benar pada confusion matrix menunjukkan bahwa model CNN mampu membedakan kondisi daun sehat dan sakit secara efektif. Keberhasilan ini dipengaruhi oleh penerapan data preprocessing dan data augmentation yang membantu model mengenali variasi citra daun. Namun demikian, masih terdapat sejumlah kecil kesalahan klasifikasi, khususnya pada citra daun sakit yang diprediksi sebagai sehat. Hal ini menunjukkan bahwa beberapa karakteristik visual penyakit tertentu memiliki kemiripan dengan daun sehat, sehingga berpotensi membingungkan model. Pengembangan lebih lanjut dapat dilakukan dengan menambah data latih, memperbaiki arsitektur CNN, atau menggunakan teknik transfer learning untuk meningkatkan performa model.

4.6 Visualisasi Hasil Prediksi Model

Selain evaluasi kuantitatif menggunakan metrik akurasi dan confusion matrix, dilakukan visualisasi hasil prediksi model CNN untuk melihat secara langsung performa model dalam mengklasifikasikan citra daun tanaman. Visualisasi ini bertujuan untuk memberikan gambaran kualitatif mengenai kesesuaian prediksi model terhadap kondisi sebenarnya pada data validasi.

Pada tahap ini ditampilkan beberapa contoh citra daun tanaman dari data validasi yang diprediksi sebagai sehat dan sakit oleh model CNN. Masing-masing citra disertai dengan label prediksi dan label sebenarnya untuk memudahkan interpretasi hasil klasifikasi. Sebanyak tiga contoh citra daun sehat dan tiga contoh citra daun sakit dipilih secara acak dari data validasi. Pemilihan sampel ini bertujuan untuk menunjukkan kemampuan model dalam mengenali karakteristik visual dari masing-masing kondisi daun.




Gambar 4.4. Visualisasi Prediksi Model CNN

Berdasarkan hasil visualisasi, sebagian besar citra daun dapat diklasifikasikan dengan benar oleh model CNN. Pada citra daun sehat, model mampu mengenali warna daun yang relatif seragam dan tidak menunjukkan pola kerusakan yang signifikan. Sementara itu, pada citra daun sakit, model dapat mengidentifikasi adanya perubahan warna, bercak, atau pola tekstur yang tidak normal. Namun, pada beberapa kasus tertentu masih ditemukan perbedaan antara label prediksi dan label sebenarnya. Hal ini mengindikasikan bahwa terdapat citra dengan karakteristik visual yang mirip antara daun sehat dan sakit, sehingga berpotensi menimbulkan kesalahan prediksi.

4.7 Analisis Distribusi Hasil Prediksi Model

Pada tahap ini dilakukan analisis distribusi hasil prediksi model CNN terhadap data yang diuji. Analisis ini bertujuan untuk melihat proporsi citra daun yang diprediksi sebagai sehat dan sakit, sehingga dapat memberikan gambaran umum kecenderungan hasil klasifikasi yang dihasilkan oleh model. Hasil prediksi model divisualisasikan dalam bentuk grafik batang yang menunjukkan jumlah citra daun yang diklasifikasikan sebagai sehat dan sakit. Grafik ini menampilkan perbandingan jumlah prediksi pada masing-masing kelas berdasarkan hasil keluaran model CNN.



Gambar 4.5. Perbandingan Jumlah Prediksi Daun Sehat dan Daun Sakit

Berdasarkan hasil tersebut, dapat dilihat bahwa jumlah citra daun yang diprediksi sebagai daun sakit jauh lebih banyak dibandingkan dengan daun sehat. Kondisi ini sejalan dengan karakteristik dataset *PlantVillage* yang memiliki proporsi citra penyakit tanaman lebih dominan dibandingkan citra daun sehat. Distribusi hasil prediksi ini menunjukkan bahwa model CNN mampu mengikuti pola distribusi data yang ada.

BAB 5

KESIMPULAN

Berdasarkan hasil penelitian yang telah dilakukan, metode Convolutional Neural Network (CNN) terbukti dapat diterapkan secara efektif dalam klasifikasi penyakit tanaman berdasarkan citra daun menggunakan dataset PlantVillage. Seluruh tahapan penelitian, mulai dari eksplorasi data, preprocessing, pembangunan arsitektur CNN, hingga proses pelatihan dan evaluasi model, menunjukkan bahwa CNN mampu mengekstraksi fitur visual daun secara otomatis dan mengenali perbedaan pola penyakit dengan baik. Hal ini menjawab rumusan masalah pertama bahwa CNN sesuai digunakan untuk permasalahan klasifikasi citra penyakit tanaman.

Hasil evaluasi menunjukkan bahwa model CNN memiliki performa yang tinggi, dengan akurasi pelatihan sebesar 86,52% dan akurasi validasi sebesar 84,79%. Selain itu, evaluasi biner antara kondisi daun sehat dan sakit menghasilkan akurasi sebesar 96,19%, yang didukung oleh hasil confusion matrix dengan dominasi prediksi benar. Meskipun masih terdapat sejumlah kecil kesalahan klasifikasi akibat kemiripan karakteristik visual antar kelas, secara keseluruhan model telah mampu mengklasifikasikan penyakit tanaman secara akurat dan stabil. Dengan demikian, penelitian ini menunjukkan bahwa CNN berpotensi dikembangkan lebih lanjut sebagai sistem pendukung deteksi dini penyakit tanaman di bidang pertanian.

DAFTAR PUSTAKA

- Chapaneri, R., Desai, M., Goyal, A., Ghose, S., & Das, S. (2020). Plant disease detection: A comprehensive survey. <https://doi.org/10.1109/CSCITA47329.2020.9137779>
- Chen, X. (2023). The study for convolutional neural network and corresponding applications. <https://doi.org/10.54254/2753-8818/5/20230387>
- Garg, T., Dwivedi, P., Mishra, M. K., Joshi, N. C., Shrivastava, N., & Mishra, V. (2024). Artificial intelligence in plant disease identification: Empowering agriculture. <https://doi.org/10.1016/bs.mim.2024.05.007>
- Gupta, R., Jebaraj, N. R. S., & Kumar, R. (2024). Deep learning using convolutional neural nets for image classification. <https://doi.org/10.1109/ICOCWC60930.2024.10470758>
- Hamami, F., & Dahlan, I. A. (2022). Classification of tomato disease using convolutional neural network. IOP Conference Series: Earth and Environmental Science. <https://doi.org/10.1088/1755-1315/1038/1/012032>
- Ilhamsyah, M., & Enri, U. (2022). Identification of bacterial spot diseases on paprika leaves using CNN and transfer learning. Jurnal Pilar Nusa Mandiri. <https://doi.org/10.33480/pilar.v18i1.2755>
- Khedkar, V. (2024). Classification of plant diseases by image processing for optimal spraying purposes. International Journal for Research in Applied Science and Engineering Technology. <https://doi.org/10.22214/ijraset.2024.60472>
- Kumar, S. (2023). Automatic leaf disease detection using convolution neural network. <https://doi.org/10.1109/CISES58720.2023.10183413>
- Kumar, S., Prasad, K., Srilekha, A., Suman, T. Y., Rao, B. P., & Krishna, J. N. V. (2020). Leaf disease detection and classification based on machine learning. <https://doi.org/10.1109/ICSTCEE49637.2020.9277379>
- Kusumo, B. S., Heryana, A., Krisnandi, D., Yuwana, S., Zilvan, V., & Pardede, H. F. (2020). Deep convolutional neural networks-based plants diseases detection using hybrid features. Computer Engineering and Applications. <https://doi.org/10.18495/COMENGAPP.V9I3.346>
- Lu, J., Tan, L., & Jiang, H. (2021). Review on convolutional neural network (CNN) applied to plant leaf disease classification. Agriculture. <https://doi.org/10.3390/agriculture11080707>

- Nikesh, M., Rohini, D., Shaankari, S., Bharathi, M., & Srinivas, T. A. S. (2024). Verdant vision: CNNs revolutionizing plant leaf disease identification. <https://doi.org/10.48001/jocsvl.2024.121-6>
- Pal, A., Adhikary, R., Satapathy, S. N., Tripathy, A., Kulkarni, C. C., & Dash, D. (2023). Smart agriculture transformation through deep learning: Revolutionizing crop productivity and sustainability. Journal of Advanced Zoology. <https://doi.org/10.17762/jaz.v44is-5.1576>
- Saleem, M., Senan, N., Wahid, F., Aamir, M., Samad, A., & Khan, M. (2022). Comparative analysis of recent architecture of convolutional neural network. Mathematical Problems in Engineering. <https://doi.org/10.1155/2022/7313612>
- Tejaswi, A. (2019). PlantVillage [Dataset]. Kaggle. <https://www.kaggle.com/datasets/arjuntejaswi/plant-village>
- Vishnoi, V. K., Kumar, K., & Kumar, B. (2021). Plant disease detection using computational intelligence and image processing. Journal of Plant Diseases and Protection. <https://doi.org/10.1007/S41348-020-00368-0>
- Voditel, P. S., Gurjar, A., Kadoo, P., & Dahake, T. (2023). Disease recognition in plant leaves using CNN-based algorithm. <https://doi.org/10.1109/ICSSAS57918.2023.10331750>